# 음성 및 텍스트 멀티모달 기반 아동·청소년 정신건강 상태 모니터링 서비스

2024311573 DA 최다솔, 2024311566 DA 김신웅, 2024311569 DA 장채연
2024311575 DA 이지환, 2024311585 DA 최환

# 목차

01
연구 배경 및 목적

02
관련 선행연구

03
데이터셋 소개

04
모델 제안

05
실험 방법

06
실험 결과

07
결론 및 기여

08
발전 가능성

# 01 연구 배경 및 목적

- 아동·청소년기의 **정신적 어려움**은 학업성취도 및 성인기의 전반적의 삶을 저하시키는 요인이 될 수 있다.
- 전국 만 9세 -17세 청소년 중 약 16%가 **정신장애**를 경험했으며, 7.1%가 즉각적인 전문가의 개입이 필요한 상태로 나타났다.
- 하지만 현재의 정신건강 관리 시스템은 전문 상담사의 수적 부족, 상담 비용의 부담, 정기적인 모니터링의 어려움이 있다.

# “아동·청소년의 정신건강 상태를 자동으로 분류하는 시스템 구축”

- ✓ 음성, 텍스트 동시 활용하는 멀티모달 모델
- ✓ 내담자의 초기 상태 평가에 활용 가능
- ✓ 물리적, 시간적 제약 없이 모니터링 가능

# 02 선행 연구 – 멀티모달 감정분류

## AIA-Net: Adaptive Interactive Attention Network for Text - Audio Emotion Recognition

IEEE Transactions on Cybernetics IEEE Trans. Cybern. Cybernetics, IEEE Transactions on. PP(99):1-13

### Zhang 외 (2022)

- Wav-RoBERTa로 오디오 임베딩
- RoBERTa를 통해 텍스트 임베딩
- 오디오와 텍스트 특징간 유사성 행렬을 Interactive Attention Weights로 변환해 텍스트 벡터에 적용
- 오디오+텍스트 단순 연결보다 뛰어난 성능

## Efficient Emotion Classification Method Based on Multimodal Approach Using Limited Speech and Text Data

*정보처리학회 논문지 (KTSDE) / The Transactions of the Korea Information Processing Society (KTSDE)*. Apr 30, 2024 13(4):174

### 신미르 외 (2024)

- wav2vec 2.0으로 오디오 임베딩
- KcELECTRA, KoBERT, KLUE-bert, KLUE-RoBERTa, KoELECTRA 각각으로 텍스트 임베딩해 비교
- 오디오+텍스트 단순 연결
- KcELECTRA 가 가장 좋은 성능

## Multi-modal emotion recognition using speech features and text-embedding

In: Applied Sciences (Switzerland). (Applied Sciences (Switzerland), 1 September 2021, 11(17))

### 변성우 외 (2021)

- 음성에서 43개의 특징 추출
- Tracotron을 통해 텍스트 임베딩
- LSTM을 통해 오디오, 텍스트 각각 분류한 후 평균해서 최종 분류
- 기존 제안된 다른 한국어 멀티모달 감정인식 모델에 비해 높은 성능

AI HUB

# 아동·청소년 상담 데이터

7~12세 상담데이터 3236건

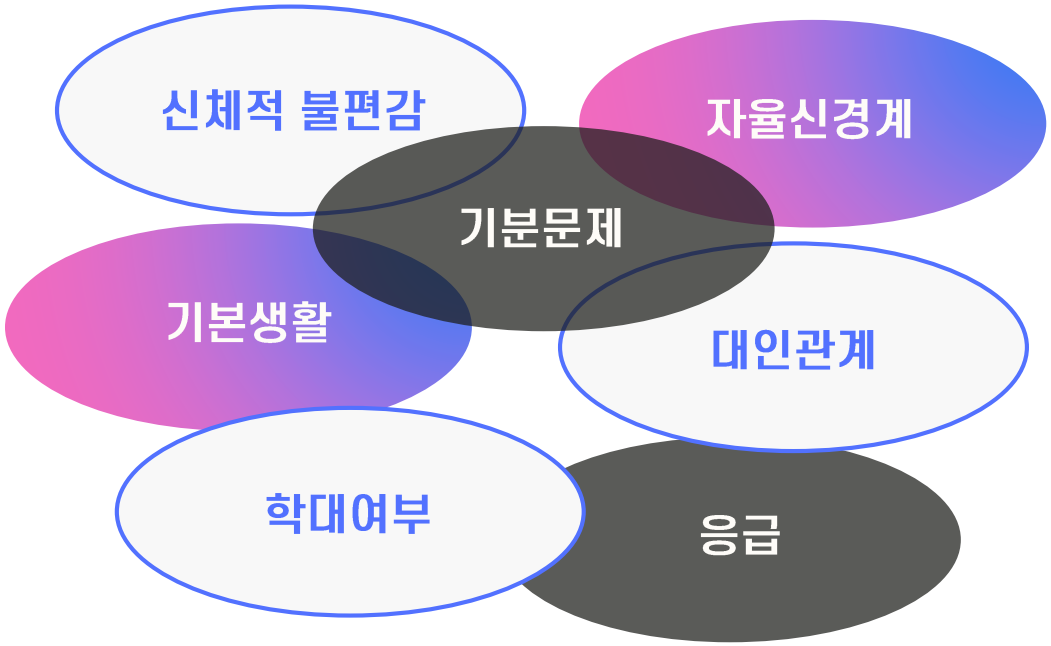


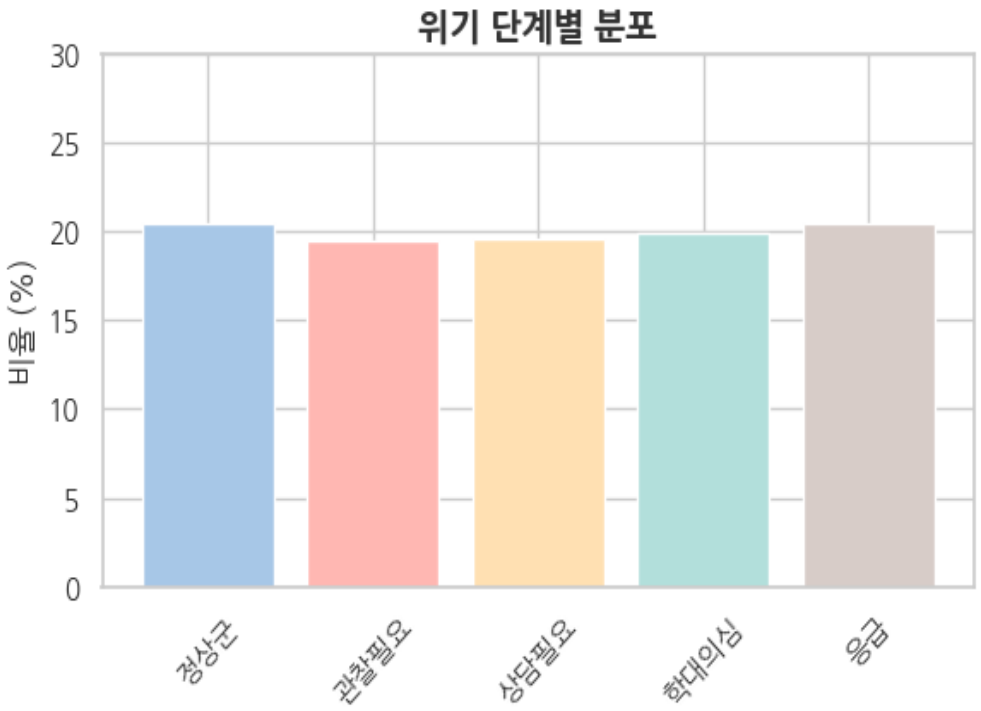

# Audio

1. 내담자의 음성만 포함된 시간의 음성을 추출 후, 이를 모두 결합
2. 고정된 sampling rate(16KHz 또는 32KHz)로 데이터를 표준화하고, 오디오 신호는 [-1,1] 범위로 스케일링

   * sampling rate :이산적인 신호를 만들기 위해 연속적 신호에서 얻어진 단위 시간(주로 초)당 샘플링 횟수

3. 다양한 Pre-trained-model 사용해 512차원 형태의 embedding vector로 변환

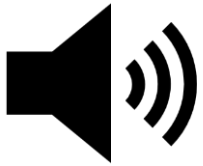

# Text

1. 상담의 전체적인 맥락을 반영하기 위해 내담자와 상담자의 대화 전체를 임베딩

   ex) 상담자: 뭘 할 때 즐거워요? 내담자: 즐거운 게 없어요.

2. Okt 형태소분석기로 형태소 분석 불용어 제거 (명사, 형용사, 부사만 사용) 하는 전처리 시도

   → 추가적인 처리 없이 전체 문장 다 넣었을 때 성능이 더 우수해 전처리 없이 진행

3. 다양한 Pre-Trained model을 사용해 512차원의 텍스트 embedding vector로 변환

## JSON to CSV

```
"Info" : {
    "Id" : "0004",
    "성별" : "여"},
"list" : [
    {"문항이름" : "신체적 불편감",
    "문항합계" : 10 ,
    "문항위기단계" : "상담필요"
```

| | id | 문항이름 | 문항합계 | 문항위기단계 | 대화 |
|---|---|---|---|---|---|
| 0 | 0004-1 | 신체적 불편감 | 10 | 상담필요 | 상담자 : 아픈 곳 있어요? 내담자 : 네. 일주일 전에 머리를 많이 맞았는데... |
| 1 | 0004-2 | 기분문제 | 12 | 상담필요 | 상담자 : 뭘 할 때 즐거워요? 내담자 : 즐거운 게 없어요 ... |
| 2 | 0004-3 | 자율신경계 | 7 | 상담필요 | 상담자 : 몇 시에 자고 몇 시에 일어나요? 내담자 : 12시에 자서 7시에... |
| 3 | 0004-4 | 대인관계 | 9 | 관찰필요 | 상담자 : 평상시에 부모님은 어떤 표정을 자주 지어요 ? 내담자 : 엄마는 ... |
| 4 | 0004-5 | 기본생활 | 20 | 상담필요 | 상담자 : 요즘 가장 큰 걱정거리가 뭐에요? 내담자 : 새아빠요 ... |
| ... | ... | ... | ... | ... | ... |

한 명의 상담 데이터를 '문항이름'을 기준으로 분리하고, 이에 따른 Label (문항위기단계)이 부여되도록 데이터 정돈

→ 3,236 개의 상담 데이터를 22,652개의 데이터로 변환

# 04 모델 제안

01 오디오와 텍스트 데이터를 각각 Speech Encoder와 Text Encoder에 입력하여 감정적인 특징을 나타낼 수 있는 512 차원(변동 가능)의 임베딩을 각각 생성

02 여러가지 Fusion Module 방식을 이용하여 두 module이 결합된 벡터 출력

03 Multimodal Projection Head에서 Contrastive Learning을 통해 동일한 감정을 가진 벡터들 간의 임베딩 거리를 좁혀, 퓨전된 특성의 표현을 효과적으로 학습

04 이전 단계에서 추출된 벡터를 Classification Head에 Feed Forward해 5개의 클래스로 최종 분류

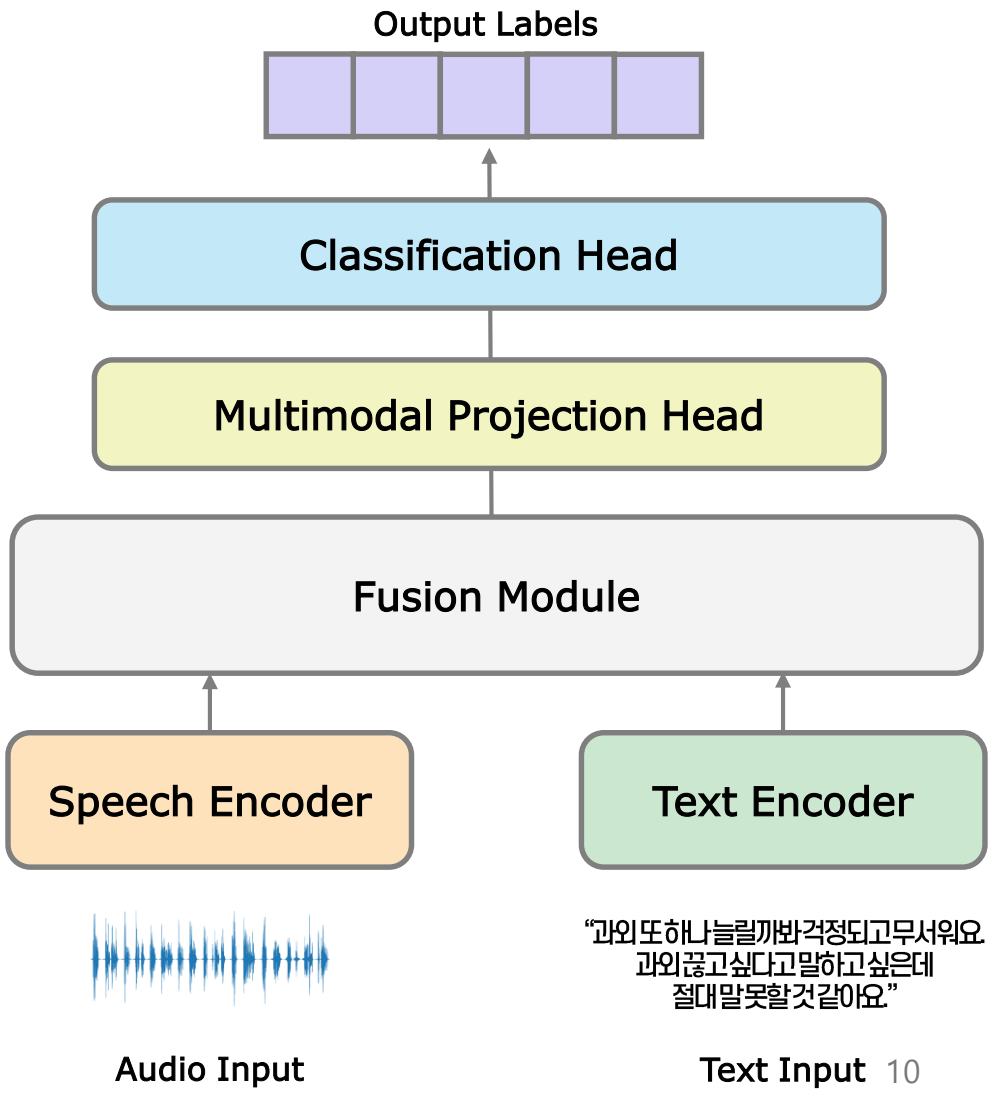

# 05 실험 방법 : 구성

텍스트 인코더

## Text–only

KcELECTRA, KoBERT, KoELECTRA, KoRoBERTa, KoRoBERTA_fine_tuning, Llama-3-Open-Ko-8B

오디오 인코더

## Audio–only

Pann, Hubert, WavLM, wav2vec2, wav2vec_finetuned

퓨전 방식

## Text & Audio

Transformer, Concat, Cross-Attention, Late

# 05 실험 방법 : 퓨전 방식

| | |
|---|---|
| Transformer Fusion | - Transformer 인코더 기반의 VATT 원본 퓨전 방식<br>- Position Embedding과 Modality Embedding을 통해 각 시퀀스의 순서와 모달리티 정보를 보존<br>- Multi-head Self-attention을 활용해 모달리티 간 상호작용을 강화 |
| Concatenation Fusion | - 각 모달리티의 특성을 단순 연결하여 하나의 벡터로 결합<br>- 다층 퍼셉트론(MLP)을 통해 결합된 특성을 통합하여 최종 표현 도출 |
| Cross-Attention Fusion | - 각 모달리티 간 Cross-Attention 메커니즘을 적용하여 특성을 상호 참조<br>- Attention 메커니즘을 통해 모달리티 간의 중요한 상호작용을 학습 |
| Late Fusion | - 각 모달리티를 독립적으로 처리한 후 최종 예측 단계에서 가중 결합<br>- 모달리티 별 예측 결과를 독립적으로 활용하여 최종 결론 도출 |

# Experiments

# Phase 1

# 06 실험 결과 : Single Modal

| Audio | |
|---|---|
| wav2vec2 | 0.646 |
| pann | 0.5426 |
| hubert | 0.5792 |
| WavLM | 0.6161 |
| wac2vec_finetuned | **0.7695** |

| Text | |
|---|---|
| KcELECTRA | 0.5708 |
| KoBERT | **0.5748** |
| KoELECTRA | 0.5698 |
| KoRoBERTa | 0.5701 |
| KoRoBERTa_finetuned | 0.5678 |

**wac2vec_finetuned**

- AI-hub 아동청소년 상담데이터 오디오 훈련 데이터셋(10GB)으로 Supervised Fine Tuning 수행
- RTX 3090 24G VRAM

**KoRoBERTa_finetuned**

- Open AI API로 전량 구축된 한국어 심리 상담 데이터셋(35.4MB)으로 MLM(Masked Language Model) Fine Tuning 수행
- RTX 3090 24G VRAM

# 06 실험 결과 : pann & BERT

| | | pann | | | |
|---|---|---|---|---|---|
| | | Transformer Fusion | Concat Fusion | Cross-Attention Fusion | Late Fusion |
| BERT | KcELECTRA | 0.5905 | 0.5516 | 0.5727 | 0.5738 |
| | KoBERT | 0.585 | 0.563 | 0.5645 | 0.5927 |
| | KoELECTRA | **0.5943** | 0.5513 | 0.546 | 0.5821 |
| | KoRoBERTa | 0.5914 | 0.5637 | 0.5676 | 0.584 |
| | KoRoBERTa _fine_tuned | 0.6046 | 0.5671 | 0.598 | 0.5637 |

# 06 실험 결과 : wav2vec2 & BERT

| | | wav2vec2 | | | |
|---|---|---|---|---|---|
| | | Transformer Fusion | Concat Fusion | Cross-Attention Fusion | Late Fusion |
| BERT | KcELECTRA | 0.6917 | 0.6775 | 0.6833 | 0.6978 |
| | KoBERT | 0.689 | 0.6634 | 0.7012 | 0.709 |
| | KoELECTRA | 0.7048 | 0.6689 | 0.6862 | 0.6946 |
| | KoRoBERTa | **0.712** | 0.6818 | 0.6647 | 0.6924 |
| | KoRoBERTa _fine_tuned | 0.7054 | 0.695 | 0.7 | 0.6609 |

# 06 실험 결과 : Hubert & BERT

| | | hubert | | | |
|---|---|---|---|---|---|
| | | Transformer Fusion | Concat Fusion | Cross_Attention Fusion | Late Fusion |
| BERT | KcELECTRA | 0.589 | 0.6056 | 0.6014 | **0.6257** |
| | KoBERT | 0.5959 | 0.5959 | 0.6056 | 0.6069 |
| | KoELECTRA | 0.609 | 0.5879 | 0.6119 | 0.6176 |
| | KoRoBERTa | 0.6176 | 0.6011 | 0.606 | 0.6185 |
| | KoRoBERTa _fine_tuned | 0.6205 | 0.6129 | 0.6133 | 0.6036 |

# 06 실험 결과 : wav2vec2_fine_tuned & BERT

| | | wav2vec2_finetuned | | | |
|---|---|---|---|---|---|
| | | Transformer Fusion | Concat Fusion | Cross_Attention Fusion | Late Fusion |
| BERT | KcELECTRA | 0.7773 | 0.7685 | 0.7725 | 0.7763 |
| | KoBERT | 0.7681 | 0.7742 | 0.7743 | 0.776 |
| | KoELECTRA | 0.7749 | 0.7697 | 0.7714 | 0.7762 |
| | KoRoBERTa | 0.7715 | 0.772 | 0.7767 | 0.775 |
| | KoRoBERTa _fine_tuned | **0.7777** | 0.7702 | 0.7688 | 0.7732 |

# 06 실험 결과 : wavLM & BERT

| | | wavLM | | | |
|---|---|---|---|---|---|
| | | Transformer Fusion | Concat Fusion | Cross_Attention Fusion | Late Fusion |
| BERT | KcELECTRA | 0.6507 | 0.6603 | 0.6479 | 0.6382 |
| | KoBERT | 0.641 | 0.6431 | 0.6443 | 0.6348 |
| | KoELECTRA | 0.6492 | 0.6396 | 0.6551 | 0.6372 |
| | KoRoBERTa | 0.6582 | 0.6604 | 0.6643 | 0.6298 |
| | KoRoBERTa _fine_tuned | 0.6615 | 0.6608 | **0.6655** | 0.6414 |

# 실험 결과 : Audio & BERT

- 일반적으로 단일 모달보다 멀티모달의 성능이 높음.
- Fine-tuned wav2vec + KoRoBERTa 조합이 가장 성능이 높음.

| Audio | |
|---|---|
| wav2vec2 | 0.646 |
| pann | 0.5426 |
| hubert | 0.5792 |
| WavLM | 0.6161 |
| wav2vec_ fine_tuned | **0.7695** |

| Text | |
|---|---|
| KcELECTRA | 0.5708 |
| KoBERT | 0.5748 |
| KoELECTRA | 0.5698 |
| KoRoBERTa | 0.5701 |
| KoRoBERTa_ fine_tuned | 0.5678 |
| Llama-3-Open -Ko-8B | 0.8138 |

| | | Wav2vec2_finetuned | | | |
|---|---|---|---|---|---|
| | | Transformer Fusion | Concat Fusion | Cross-Attention Fusion | Late Fusion |
| BERT | KcELECTRA | 0.7773 | 0.7685 | 0.7725 | 0.7763 |
| | KoBERT | 0.7681 | 0.7742 | 0.7743 | 0.776 |
| | KoELECTRA | 0.7749 | 0.7697 | 0.7714 | 0.7762 |
| | KoRoBERTa | 0.7715 | 0.772 | 0.7767 | 0.775 |
| | KoRoBERTa _fine_tuned | **0.7777** | **0.7702** | **0.7688** | **0.7732** |

# Experiments

# Phase 2

# 실험 결과: LLM

## Llama-3-Open-Ko-8B

- Llama-3 based Korean fine-tuned LLM
- 데이터셋: 60GB 이상의 Open-Solar-Ko 데이터셋
    - AI-hub
    - 모두의 말뭉치
    - 한국어 위키피디아
- 파라미터: 8B
- 컨텍스트 길이: 8k
- 토큰 수: 17.7B이상

| | |
|---|---|
| **Llama-3-Open-Ko-8B** | **0.8238** |

# 07 실험 결과 : wav2vec2 & LLM

| | | wav2vec2 | | | |
|---|---|---|---|---|---|
| | | Transformer Fusion | Concat Fusion | Cross_Attention Fusion | Late Fusion |
| Llama-3-Open-Ko-8B | "batch_size": 64,<br>"feature_dim": 256,<br>"num_epochs": 20,<br>"learning_rate": 1e-4,<br>"contrastive_weight": 0.5, | 0.8221 | 0.8186 | 0.8296 | 0.8285 |
| | "batch_size": 64,<br>"feature_dim": 512,<br>"num_epochs": 20,<br>"learning_rate": 1e-5,<br>"contrastive_weight": 0.5, | 0.8329 | 0.8135 | 0.822 | 0.8257 |
| | "batch_size": 64,<br>"feature_dim": 512,<br>"num_epochs": 20,<br>"learning_rate": 1e-5,<br>"contrastive_weight": 0.3, | **0.8388** | 0.8095 | 0.8185 | 0.8318 |

# 07 | 실험 결과 : wav2vec2_fine_tuned & LLM

| | | wav2vec2_finetuned | | | |
|---|---|---|---|---|---|
| | | Transformer Fusion | Concat Fusion | Cross_Attention Fusion | Late Fusion |
| Llama-3-Open-Ko-8B | | | | | |
| | | | | | |
| | "batch_size": 64, "feature_dim": 512, "num_epochs": 20, "learning_rate": 1e-5, "contrastive_weight": 0.3 | **0.7883** | 0.7845 | 0.7865 | 0.794 |

# 07 | 실험 결과: Audio & LLM

- 한국어로 파인튜닝된 LLM의 텍스트 이해 성능이 전체 모델의 성능에 가장 큰 영향을 미침
- 단일 **모달일 때 가장 성능이 뛰어났던** fine_tuned wav2vec2**은 멀티모달로 결합했을 때, 성능이 오히려 떨어지는 현상 보임**
- 한 모달의 성능이 우세하면, 다른 모달이 성능 향상에 기여하는 효과가 미미한 것을 확인

| Audio | |
|---|---|
| wav2vec2 | 0.646 |
| pann | 0.5426 |
| hubert | 0.5792 |
| WavLM | 0.6161 |
| wac2vec_ fine_tuned | **0.7695** |

| Text | |
|---|---|
| KcELECTRA | 0.5708 |
| KoBERT | 0.5748 |
| KoELECTRA | 0.5698 |
| KoRoBERTa | 0.5701 |
| KoRoBERTa_ fine_tuned | 0.5678 |
| Llama-3-Open-Ko-8B | **0.8138** |

| | | wav2vec2 | | | |
|---|---|---|---|---|---|
| | | Transformer Fusion | Concat Fusion | Cross-Attention Fusion | Late Fusion |
| Llama-3-Open-Ko-8B | 버전1 | 0.8221 | 0.8186 | 0.8296 | 0.8285 |
| | 버전2 | 0.8329 | 0.8135 | 0.822 | 0.8257 |
| | 버전3 | **0.8388** | 0.8095 | 0.8185 | 0.8318 |
| | | wav2vec2_fine_tuned | | | |
| | | **0.7883** | 0.7845 | 0.7865 | 0.794 |

## 기술적 기여

1. 멀티모달 접근 방식의 검증

   - 음성과 텍스트를 결합한 멀티모달 분석의 효과성 입증

   - 다양한 모델 조합의 성능 비교 분석 제공

2. 한국어 특화 모델 활용

   - 한국어로 파인튜닝한 Llama-3-Open-Ko-8b 모델 적용

   → 기존 BERT 계열 모델 대비 우수한 성능 달성

   - 한국어 상담 context에 최적화된 텍스트 분석 구현

3. 상담 도메인 특화 Label 사용

   - 단순 감정이 아닌 정신건강 상태와 관련된 label 활용

   Ex) 관찰필요, 상담필요, 학대의심

## 사회적 기여

1. **정신건강 관리 시스템의 접근성 향상**

   - 상담 비용 부담 경감 가능성 제시

   - 정기적인 모니터링의 실현 가능성 제시

2. **조기 개입 가능성 향상**

   - 자동화된 모니터링을 통한 위험군 조기 발견 지원

   - 아동 · 청소년의 정신건강 문제 예방에 기여

# 09 | 발전 가능성

1. 두 모달을 결합하는 방식에 대한 추가적인 연구
2. 특히 오디오도 LLM과 같이 대규모 파라미터를 가진 모델이 공개된다면, 이 모델을 사용해 임베딩을 추출해 더 높은 성능을 낼 수 있을 것으로 기대됨

   * wavLM (audio) : 3억 1700만 개 파라미터 < Llama3-8b (text) : 80억 개 파라미터

3. 추후 STT 기술 및 모델 경량화를 이용한 On-Device 기술을 결합해 실시간 정신 건강 상태 모니터링 서비스를 제공할 수 있을 것으로 기대됨

# E.O.D

# Appendix

## F1-score

| | Hyper Parameters | wav2vec2 | | | |
|---|---|---|---|---|---|
| | | Transformer Fusion | Concat Fusion | Cross Attention Fusion | Late Fusion |
| **Llama-3-Open-Ko-8B** | "batch_size": 64,<br>"feature_dim": 512,<br>"num_epochs": 20,<br>"learning_rate": 1e-5,<br>"contrastive_weight": 0.3 | 0.8302 | 0.8114 | 0.8062 | 0.8318 |

# Appendix

## **Confusion Matrix – Multi-Modality** (Text: Llama3-Open-Ko-8B & Audio: wav2vec2)

Label = {0: '정상군', 1: '관찰 필요', 2: '상담 필요', 3: '학대 의심', 4: '위기 아동'}

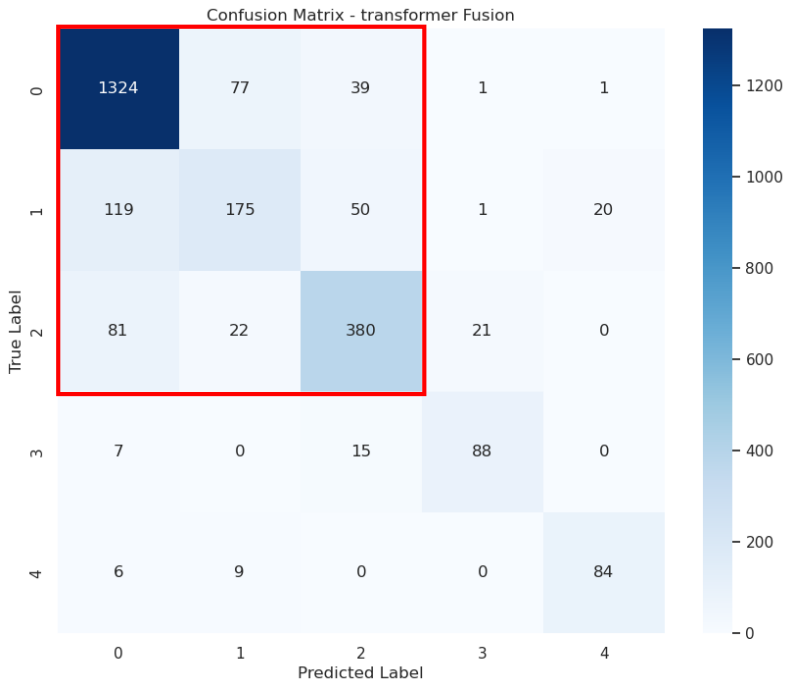


**Transformer Fusion**

**Concat Fusion**

# Appendix

## **Confusion Matrix – Multi-Modality** (Text: Llama3-Open-Ko-8B & Audio: wav2vec2)

Label = {0: '정상군', 1: '관찰 필요', 2: '상담 필요', 3: '학대 의심', 4: '위기 아동'}

- **전반적으로 '관찰 필요(1)' 를 '정상군(0)'으로 잘못 분류하는 경향이 있지만, '정상군', '상담 필요'는 전반적으로 올바르게 분류됨**

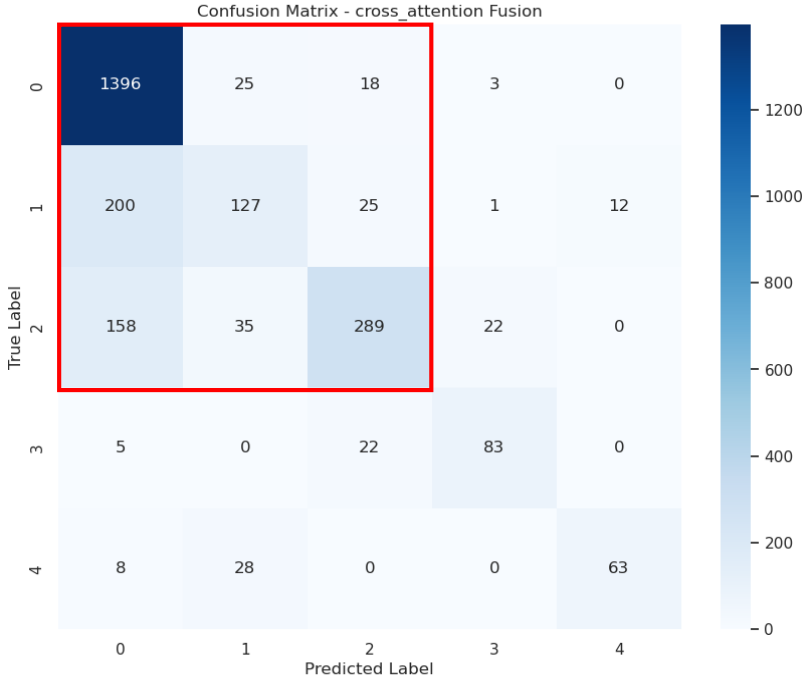


**Cross_Attention Fusion**

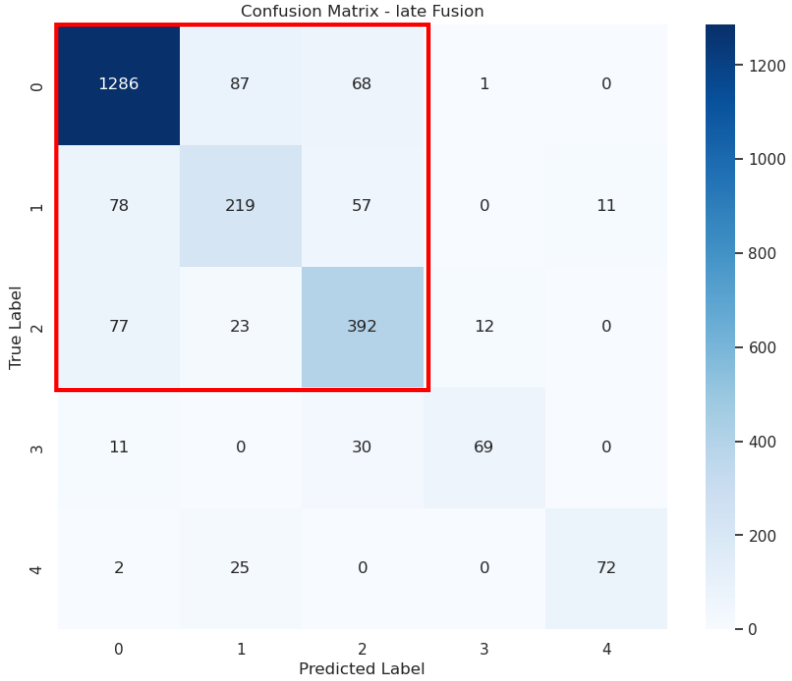


**Late Fusion**

# Appendix

## **Confusion Matrix – Uni-Modality** (Text: Llama3-Open-Ko-8B & Audio: wav2vec2)

Label = {0: '정상군', 1: '관찰 필요', 2: '상담 필요', 3: '학대 의심', 4: '위기 아동'}

- **Text Only에서도 Multi-Modality에서 나타나는 경향성을 보임. 그러나 Audio Only에서는 상대적으로 '관찰 필요'의 오분류율 높음**

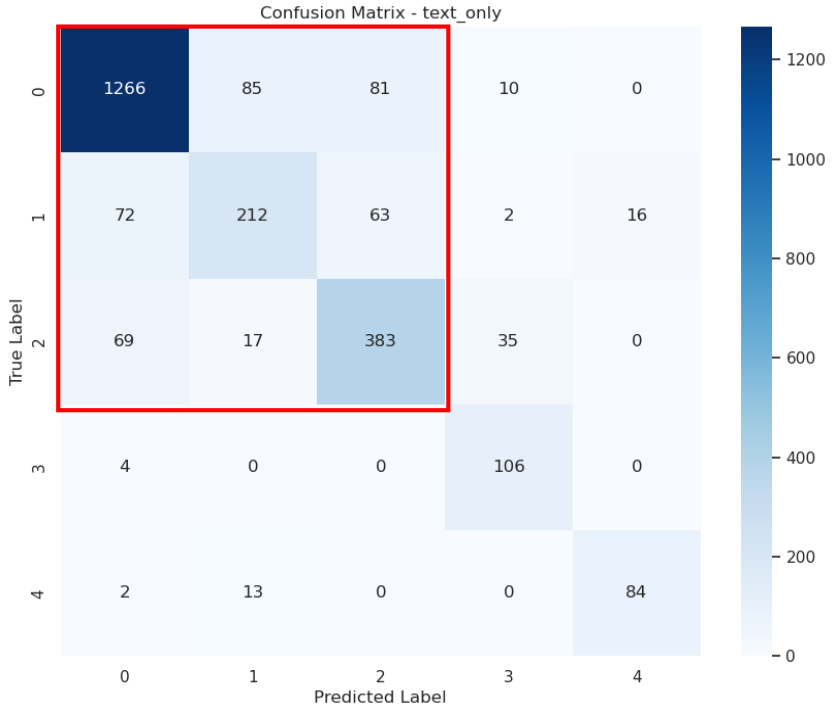


**Text Only**

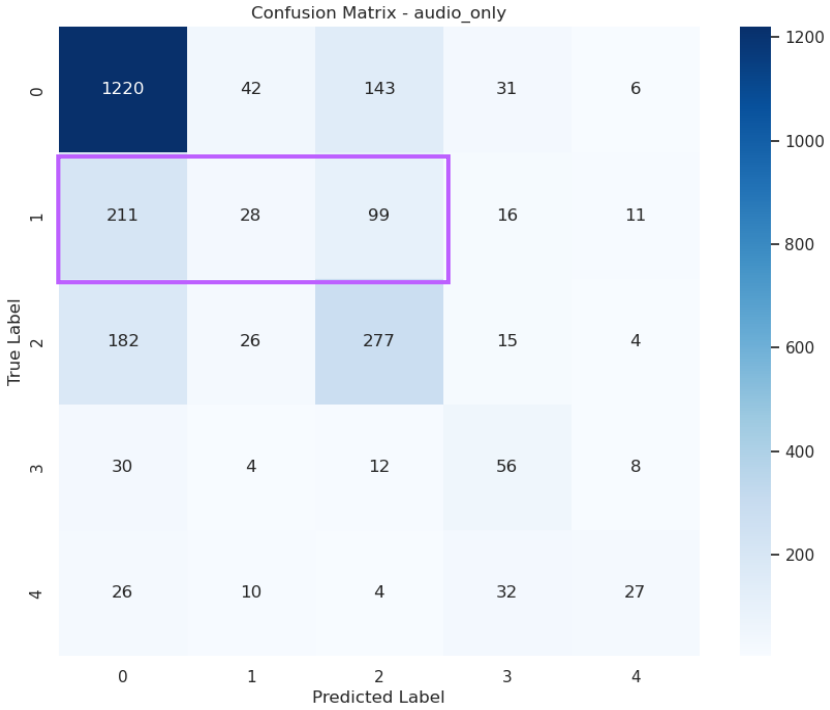


**Audio Only**